

Bilmerkegjennkjennning

Navn: Mahdi Mohammadi og David-Patrick Bonsu Obeng

Dato: 2.11.2025

Problembeskrivelse

I dette prosjektet har vi utviklet et system som kan gjenkjenne bilmerker basert på bilder. Hovedideen er at brukeren kan laste opp et bilde av en bil, og systemet skal automatisk forutsi hvilket bilmerke det er. Systemet vårt er trent å gjenkjenne fire bilmerker, BMW, Toyota, Audi og Mercedes. Målet med prosjektet er å lage en enkel men fungerende prototype som viser hvordan maskinlæring kan brukes i praksis for bilmerkegjennkjennning.

Metrikker

For å vurdere hvor godt modellen fungerer, brukte vi accuracy (treffsikkerhet) om hovedmåling. Denne metrikken viser hvor mange av bilene som ble riktig klassifisert av systemet. Målet vårt er å oppnå minst 60% treffsikkerhet, og i testene våre fikk vi resultater som varierte fra 40% til 100%, avhengig av datasettet og bildene som ble brukt.

Vi observerte at i mange tilfeller klarte modellen å treffe riktig merke på alle testbilder, mens den i andre tilfeller hadde større vansker, for eksempel kunne et bilde av en BMW bli klassifisert som en Toyota eller Audi. Dette tyder på at modellen fremdeles har utfordringer med ubalanse dataene og for lite variasjon i treningsbildene.

Siden dette er et klassifikasjonsproblem med fire klasser, ville tilfeldig gjetting gitt omtrent 25 % treffsikkerhet. Modellen vår klarte 55,5 %, altså mer enn dobbelt så bra som ren tilfeldighet og dette viser at faktisk systemet faktisk lærer mønstre i dataene, selv om det er rom for forbedring.

DATA

Vi hentet data fra kaggle.com om inneholder mange åpne bildesett av biler.

Totalt brukte vi 2113 bilder fordelt på fire merker.

- Toyota: 814 bilder
- Audi: 889 bilder
- BMW: 303 bilder
- Mercedes: 107 bilder

Bildene varierer i størrelse, kvalitet, lysforhold og bakgrunn. Alle er i formater som JPG, PNG eller Webp. Den store variasjonen i bakgrunn og vinkel gjør at modellen må lære å fokusere på selve bilen og ikke på omgivelsene, noen som krevende og mer realistisk.

Et viktig poeng i i datasettet vårt er at klassene er ubalansert. Toyota og Audi har langt flere bilder enn BMW og Mercedes, noe som gjør at modellen lærer mer om disse merkene. Dette påvirker nøyaktigheten negativt for de merkene som har færre bilder.

Når det gjelder etiske hensyn, har vi kun brukt offentlig tilgjengelige bilder uten synlige registreringsnumre eller personer. Vi har vært bevisst på personvern og forsøkt å bruke bilder som ikke identifiserer enkeltpersoner.

Modellering

Vi valgte k-Neares Neighbor (k-NN) som maskinlæringsmodell, med parameterne $k=5$.

Denne algoritmen fungerer ved å sammenligne et nytt bilde med alle treningsbildene, finne de fem mest like, og deretter stemme på hvilket merke som er mest sannsynlig.

Fordeler med k-NN er at lett å forstå og implementere, ingen tung trening nødvendig og fungerer godt for små datasett. Selv om k-NN ikke er den mest avanserte algoritmen, er den svært nyttig i tidlige faser av et prosjekt for å etablere en baseline og forstå hvordan dataene oppfører seg.

Ytelse:

- Toyota: 84% recall, veldig bra.
- Audi: 44% recall, middels.
- BMW: 17% recall, svakt.
- Mercedes: 12% recall, veldig svakt.

Resultatene viser tydelig at modellen presterer bedre på de merkene som har flest bilder.

Feilene vi observerte kom ofte fra bildene ble vist fra uvante vinkler, bilden hadde dårlig lys eller kontrast, bakgrunn var kompleks eller bildene hadde lignende farger en annen merke. Et eksempel er at mørke Mercedes-biler ofte ble klassifisert som BMW, og grunnen kanskje være at begge merkene har mange bilder av mørke biler i datasettet.

Det finnes flere måter vi kan forbedre modellen på.

En av de viktigste tingene er å samle inn mer og mer balansert data, spesielt flere bilder av BMW og Mercedes, slik at alle bilmerkene får omtrent like mange eksempler. Dette vil gjøre treningen mer rettferdig og gi modellen bedre mulighet til å lære forskjellene mellom merkene.

En annen forbedring er å legge til flere bildeegenskaper, også kalt *features*. I stedet for å bare bruke farger, kan vi inkludere informasjon om kanter og form. Dette vil hjelpe modellen med å forstå strukturen i bilene bedre, og ikke bare basere seg på fargemønstre. Vi kan også bruke en annen teknikk som heter data augmentation. Det betyr at vi endrer eksisterende bilder ved å rotere dem, speilvende dem eller justere lysstyrken. På den måten øker vi variasjonen i datasettet uten å måtte samle inn nye bilder.

Og til slutt kan vi prøve mer avanserte maskinlæringsmodeller, som Random Forest eller enkle nevralt nettverk. Disse modellene kan oppdage mer komplekse mønstre i bildene og gi bedre resultater.

Ved å kombinere alle disse tingene tror vi kan forbedre modellen mye mer.

Deployment

For å gjøre systemet tilgjengelig for brukerne, laget vi en enkel webapp i Streamlit. Appen lar brukeren laste opp et bilde, og deretter kan trykke på "Analyse" og se resultatet med sannsynlighet for hvert bilmerke.

Referanser

<https://www.kaggle.com/datasets/kshitij192/cars-image-dataset>

<https://www.kaggle.com/datasets/yamaerenay/100-images-of-top-50-car-brands>

Vi brukte OpenAI Chat-GPT som støtte i utvikling av prosjektet